

Reporte

Integrantes

- Josue Say - 228801
- Flavio Galán - 22386

Repositorio

- [Enlace](#)
- [Modelos](#)

Nota: se está utilizando python 3.12.3 y para no entrenar nuevamente los modelos se recomienda descargar los modelos por el enlace y descomprimirlos, dejar la carpeta models dentro de lab6.

En la carpeta [docs/algorithms](#) se encuentran los documentos de referencias y explicación de los 2 métodos implementados para que se pueda ver un mayor detalle con un workflow base.

Descripción de los datos

- **id:** Identificador único del tweet.
- **keyword:** Palabra clave asociada al tweet (puede estar en blanco).
- **location:** Ubicación desde donde se envió el tweet (puede estar vacía).
- **text:** El contenido del tweet.
- **target:** Etiqueta binaria (1 = tweet sobre un desastre real, 0 = no relacionado con desastre).

Ejemplo de registros:

```
1,,,Our Deeds are the Reason of this #earthquake May ALLAH Forgive us all,1
235,airplane%20accident,India,OMG Horrible Accident Man Died in Wings of Airplane. <http://t.
```

Análisis exploratorio


- Se identificaron palabras frecuentes diferenciadas por clase (target=1 desastre real vs target=0 no relacionado).
- Top palabras clase 1: fire, disaster, suicide, storm, crash, killed...
- Top palabras clase 0: like, new, get, one, video, people, love...
- Intersecciones: fire, people, video, police, lo que resalta la necesidad de n-gramas para desambiguar.

- Se realizaron **nubes de palabras** y gráficos de frecuencias para confirmar que la limpieza eliminó ruido (emojis, URLs, menciones).

Desastres (Top Unigramas)



No desastres (Top Unigramas)




Limpieza y preprocesamiento de datos

- Eliminación de **URLs, menciones, hashtags, emojis y caracteres Unicode raros.**
- Reducción de la longitud media de los tweets en un **44%** (de 101.2 a 56.7 caracteres).
- Tokenización estándar en minúsculas.

Generación de n-gramas y frecuencias/probabilidades

- Se probaron tres vistas del texto:

- **Unigramas.**
- **Uni+bi-gramas.**
- **Caracteres 3-5** (para manejar errores ortográficos y hashtags).
- Los **bigramas** aportaron contexto relevante: forest fire, train crash, car accident.
- Los trigramas fueron menos útiles por la escasez de ocurrencias.



Modelos clasificadores

Baseline: TF-IDF + Clasificadores lineales

- Tres vectorizadores: TF-IDF unigrama, uni+bi, caracteres 3-5.
- Tres clasificadores: Logistic Regression (L2, balanceado), Naive Bayes, Linear SVC.
- **Selección por F1** en validación (80/20).

Mejor combinación:

- tfidf_char (3-5) + LogisticRegression.
- **F1 $\approx$ 0.768, Accuracy $\approx$ 0.804.**
- Matriz de confusión: tn=732, fp=137, fn=161, tp=493.
- Guardado en ./models/baseline_best.joblib.

Modelo avanzado: BERT + CNN

- **Encoder:** distilbert-base-uncased (PyTorch, congelado por CPU).
- **Cabeza CNN:** filters=32, kernel=3, dropout=0.5.
- Entrenamiento con RMSprop, early stopping (se detuvo en la época 7/10).
- Umbral de decisión: 0.5.

Resultados:

- **F1 $\approx$ 0.773, Accuracy $\approx$ 0.825.**
- Matriz de confusión: tn=802, fp=67, fn=200, tp=454.
- Mejora sobre el baseline: **+0.5 en F1, +2.1 en Accuracy.**
- Perfil de error: menos falsos positivos, más falsos negativos.

Función de clasificación

- Implementada una función que recibe un tweet crudo, aplica preprocesamiento y devuelve:
 - Etiqueta binaria (1=desastre, 0=no desastre).
 - Probabilidad asociada.

Clasificación de sentimiento

- Se generó una variable de **positividad/negatividad** basada en diccionarios y métricas de polaridad.
- Esto permitió agregar contexto adicional al modelo y analizar patrones de tweets negativos vs positivos.

Variable de “negatividad del tweet”

- Nueva variable cuantitativa que mide la carga negativa.
- Sirve para reforzar la clasificación binaria principal.
- El modelo se reentrenó con esta variable, logrando mayor sensibilidad en tweets negativos relacionados con desastre.

Resultados

- **Baseline (TF-IDF + Logistic Regression):** F1 = 0.768.
- **BERT+CNN:** F1 = 0.773, Accuracy = 0.825.
- Los **ngrams de caracteres** demostraron ser muy efectivos en tweets cortos y ruidosos.

- **Conclusión:** BERT+CNN supera a la línea base, pero cada uno presenta perfiles de error distintos (BERT reduce FP, baseline captura más FN).

Se confirma que la combinación de **limpieza + n-gramas + embeddings contextuales** permite clasificar con buena precisión si un tweet está relacionado con un desastre real.